

UNIVERSIDADE PRESBITERIANA MACKENZIE

GUSTAVO AZEVEDO GOMYDE

RICARDO DE OLIVEIRA VIEIRA FRANCO

ANÁLISE DO MERCADO DE TECNOLOGIA IOT NO BRASIL

Sistema de recomendação para qualificação de potenciais clientes em tecnologia IoT no Brasil

São Paulo

2026

UNIVERSIDADE PRESBITERIANA MACKENZIE

GUSTAVO AZEVEDO GOMYDE

RICARDO DE OLIVEIRA VIEIRA FRANCO

ANÁLISE DO MERCADO DE TECNOLOGIA IOT NO BRASIL

Sistema de recomendação para qualificação de potenciais clientes em tecnologia IoT no Brasil

Artigo apresentado à Universidade Presbiteriana Mackenzie como parte das exigências da matéria de “Projeto Aplicado III” do curso de “Tecnologia em Banco de Dados: Análise, Mineração e Engenharia de Dados” da turma 201825166.000.04A no 1º semestre de 2026.

Docente: Prof. Dr. Gustavo Scalabrini Sampaio

São Paulo

2026

RESUMO

Este trabalho apresenta o desenvolvimento de um sistema de recomendação voltado para a prospecção de empresas no cenário B2B brasileiro, utilizando a base de dados pública de CNPJs do Ministério da Fazenda. O objetivo é transformar a busca por novos clientes em um processo orientado a dados (data-driven), superando as limitações dos métodos tradicionais de marketing. A metodologia proposta consiste no processamento de Big Data para identificar organizações similares a uma empresa-alvo escolhida pelo usuário, permitindo filtros por localização e porte. O estudo destaca-se pela abordagem técnica comparativa, analisando o desempenho e a precisão dos algoritmos K-Nearest Neighbors (KNN) e Cosine Similarity através de uma prova de conceito. Os resultados esperados incluem a otimização da geração de leads e a validação de modelos de similaridade aplicados a dados cadastrais públicos.

Palavras-chave: Sistemas de Recomendação; Ciência de Dados; Prospecção B2B; Similaridade de Dados; Big Data.

ABSTRACT

This study presents the development of a recommendation system aimed at business prospecting within the Brazilian B2B landscape, utilizing the Ministry of Finance's public corporate database (CNPJ). The goal is to transform the search for new clients into a data-driven process, overcoming the limitations of traditional marketing methods. The proposed methodology involves Big Data processing to identify organizations similar to a target company selected by the user, allowing for filters based on location and business size. The research stands out for its comparative technical approach, analyzing the performance and accuracy of the K-Nearest Neighbors (KNN) and Cosine Similarity algorithms through a proof of concept. Expected results include the optimization of lead generation and the validation of similarity models applied to public registration data.

Keywords: Recommendation Systems; Data Science; B2B Prospecting; Data Similarity; Big Data.

Sumário

- 1. INTRODUÇÃO 8
 - 1.1. CONTEXTO DO TRABALHO 8
 - 1.2. MOTIVAÇÃO..... 9
 - 1.3. JUSTIFICATIVA 9
 - 1.4. OBJETIVO 9
 - 1.4.1. OBJETIVO GERAL..... 9
 - 1.4.2. OBJETIVO ESPECIFICO..... 10
 - 1.5. DATASET..... 10
- 2. DEFINIÇÃO DO GRUPO DE TRABALHO 12
- 3. REFERENCIAL TEÓRICO 13
 - 3.1. FUNDAMENTAÇÃO TEÓRICA: A PERSPECTIVA DE AMARASINGHE (2025) SOBRE MÉTRICAS DE VETORES..... 13
 - 3.2. A INSUFICIÊNCIA DA DIREÇÃO (COSSENO) 14
 - 3.3. A PRIMAZIA DA MAGNITUDE (EUCLIDIANA/KNN)..... 14
 - 3.4. SÍNTESE INTERPRETATIVA..... 14
- 4. PROVA DE CONCEITO 15
 - 4.1. DEFINIÇÃO DAS BIBLIOTECAS PYTHON..... 15
 - 4.2. ANÁLISE EXPLORATORIA DA BASE DE DADOS 17
 - 4.3. PREPARAÇÃO DA BASE DE DADOS..... 22
 - 4.4. DEFINIÇÃO DA TÉCNICA DE TREINAMENTO 24
 - 4.5. TREINAMENTO DO MODELO 25
 - 4.6. AVALIAÇÃO DE DESEMPENHO 27
- 5. METODOLOGIA..... 30
 - 5.1. DEFINIÇÃO DO PROBLEMA E OBJETIVOS..... 31
 - 5.2. COLETA DE DADOS..... 31
 - 5.3. PRÉ-PROCESSAMENTO E LIMPEZA DOS DADOS 33
 - 5.4. DIVISÃO DOS DADOS 36
 - 5.5. SELEÇÃO E IMPLIMENTAÇÃO DO ALGORITMO..... 38
 - 5.6. TREINAMENTO DO MODELO 38
 - 5.7. AVALIAÇÃO DO DESEMPENHO 38
 - 5.8. OTIMIZAÇÃO E AJUSTE 39
 - 5.9. IMPLANTAÇÃO E MONITORAMENTO 40
- 6. RESULTADOS 42
- 7. CONCLUSÃO 50
- CRONOGRAMA..... 52

REFERÊNCIAS	53
GLOSSÁRIO	54
APÊNDICE A – LINK DO VIDEO NO YOUTUBE.....	56
APÊNDICE B – LINK PARA GITHUB	57
LOCAL	57
APÊNDICE C – LINK PARA DATASET	58
LOCAL	58
ANEXO A – LAYOUT DAS TABELAS PARA DADOS ABERTOS DO CNPJ	59

LISTA DE ILUSTRAÇÕES

Figura 1 - Organização dos arquivos de metadados da base de CNPJ da receita federal.....	17
Figura 2 - Tamanho da base de dados.....	17
Figura 3 - Base de dados da receita federal	18
Figura 4 - Importação e início da análise exploratória.....	19
Figura 5- Análise dos primeiros registros nulos e codificação da base.....	20
Figura 6 - Diferentes tabelas com diferentes codificações	20
Figura 7- Fim da análise exploratória	21
Figura 8- Tratamento dos valores nulos.....	22
Figura 9 - Merge inicial.....	22
Figura 10 - Verificação e validação após merge	23
Figura 11 - Merge final de todas as tabelas	23
Figura 12 - Preparação e treinamento de modelo	25
Figura 13 - Teste após treinamento	26
Figura 14 - Testando o modelo com dois filtros, porte e localização.	27
Figura 15 - Resultado da primeira POC	27
Figura 16 - Testando o modelo somente com porte da empresa.....	28
Figura 17 - Resultado segundo teste.....	28
Figura 18 - testando empresas estrangeiras relacionados ao CNAE.....	29
Figura 19 - Resultado terceiro teste.....	29
Figura 20 – Fluxograma da metodologia usada	30
Figura 21 – Setup do Dataset	31
Figura 22 – Primeira Visualização do Dataset	31
Figura 23 – Ajuste do Dataset	32
Figura 24 – Finalizando ajuste do Dataset	32
• Figura 25 – Trecho de código para pré-processamento e limpeza dos dados.....	33
Figura 26 – Visualização da base unificada e pré-processada	34
Figura 27 – Dificuldades em manipular tantos registros com recursos limitados do Colab.....	34
Figura 28 – Nova base amostral 10%.	35
Figura 28 – Limpando a base atual de 10%.....	35
Figura 30 – Este gráfico identifica as atividades econômicas mais frequentes na base.....	36

Figura 31 – Representa o valor investido nas empresas, utilizando uma escala logarítmica.....	37
Figura 32 – Mostra a evolução temporal da criação de empresas	37
Figura 33 – Gráfico com todas as empresas ativas	38
Figura 34 – Score final para eficiência computacional.....	42
Figura 35 – Validação Qualitativa.....	43
Figura 36 – Mostra a distribuição geográfica das empresas.....	44
Figura 37 – Classifica as empresas pelo seu tamanho oficial.....	44
Figura 38 – Usando interface de busca	45
Figura 39 – Primeiros resultados.....	46
Figura 40 – Continuação dos testes	47
Figura 41 – Teste final	48
Figura 42– Tarefas com datas, dependências e responsáveis das atividades	52

LISTA DE TABELAS

Tabela 1 – Comparações entre KNN e Similaridade de Cosseno.	13
Tabela 2 – Glossário.	55

1. INTRODUÇÃO

No atual cenário de transformação digital, o volume de dados gerado por transações comerciais, interações digitais e registros governamentais atingiu proporções sem precedentes, consolidando a era do Big Data. No Brasil, um dos maiores ativos informacionais disponíveis é a base de dados nacional de empresas cadastradas, gerenciada pelo Ministério da Fazenda. Este ecossistema de informações, composto por dados do Cadastro Nacional da Pessoa Jurídica (CNPJ), oferece uma oportunidade única para o desenvolvimento econômico, desde que processado com ferramentas adequadas de Ciência de Dados. Nesse contexto, os Sistemas de Recomendação (SR) surgem como soluções tecnológicas indispensáveis, atuando como filtros inteligentes capazes de mitigar a sobrecarga de informações e fornecer insights estratégicos personalizados para o mercado.

Tecnicamente, um sistema de recomendação é definido como um algoritmo de filtragem de informação que busca prever a afinidade, o interesse ou a similaridade entre diferentes entidades. Embora essas tecnologias sejam amplamente reconhecidas por seu sucesso em plataformas de consumo massivo (B2C), como sugestão de filmes ou produtos, sua aplicação no setor Business-to-Business (B2B) eleva substancialmente o patamar da inteligência de mercado.

1.1. CONTEXTO DO TRABALHO

A fundamentação deste projeto repousa sobre a Base de Dados Nacional de Empresas, gerida pelo Ministério da Fazenda. Este repositório público contempla o registro histórico de todas as entidades jurídicas do país, abrangendo um universo superior a 78 milhões de registros, que incluem desde empresas ativas até unidades inativas ou baixadas.

A relevância pedagógica e técnica desta base reside na sua abrangência e granularidade. Para este trabalho, os dados essenciais serão processados para a construção de um Sistema de Recomendação fundamentado em Inteligência Artificial. A solução proposta opera a partir de uma "empresa-alvo", utilizando algoritmos de similaridade para identificar organizações com perfis análogos.

Esta aplicação configura-se como uma ferramenta estratégica de benchmarking e inteligência de mercado, permitindo:

- **Análise Setorial:** Identificação célere do volume e da capilaridade de empresas em segmentos específicos.
- **Mapeamento de Concorrência:** Visualização direta de players que disputam o mesmo nicho de mercado.
- **Prospecção Ativa:** Otimização na montagem de pipelines de vendas e identificação de potenciais parceiros ou clientes.

Dessa forma, o uso de IA sobre esta base governamental não apenas valida a viabilidade técnica do modelo, mas demonstra sua utilidade prática na automação de processos complexos de análise corporativa.

1.2. MOTIVAÇÃO

A motivação central para este estudo reside na observação de um hiato tecnológico persistente no setor comercial brasileiro. Tradicionalmente, a prospecção B2B fundamenta-se em métodos analógicos de alta intensidade operacional, como a participação em feiras setoriais e prospecções ativas baseadas puramente na intuição de mercado. Tais métodos apresentam limitações críticas em termos de escalabilidade e precisão. A necessidade de transformar essa prospecção passiva e manual em uma prospecção preditiva — que reduza o Custo de Aquisição de Clientes (CAC) e aumente a eficiência das equipes — é o que impulsiona a busca por soluções automatizadas de recomendação..

1.3. JUSTIFICATIVA

A relevância deste trabalho fundamenta-se na necessidade de transição para uma cultura Data-Driven no setor comercial brasileiro, onde a Ciência de Dados é aplicada para extrair valor estratégico de bases massivas, como o programa "Dados Abertos" do Governo Federal.

Sob a ótica da gestão, a importância do projeto manifesta-se na capacidade de gerar inteligência competitiva em escala. Ao automatizar a identificação de empresas-alvo, a solução permite uma otimização radical da geração de leads, reduzindo o esforço manual e focando a energia das equipes de vendas em clusters de oportunidades com maior probabilidade de conversão.

Do ponto de vista acadêmico, a pesquisa justifica-se pelo desafio técnico intrínseco ao processamento de dados estruturados e semiestruturados coletados entre 2021 e 2026. A manipulação de grandes volumes de dados governamentais exige o domínio de técnicas avançadas de pré-processamento e a aplicação rigorosa de algoritmos de similaridade. Assim, o estudo contribui para a fronteira do conhecimento em Inteligência Artificial ao validar qual métrica de distância — K-Nearest Neighbors ou Cosine Similarity — apresenta maior eficácia no contexto específico de dados cadastrais empresariais.

1.4. OBJETIVO

Para atender a essa demanda, o objetivo central deste trabalho é o desenvolvimento de um sistema de recomendação de empresas fundamentado na análise de similaridade. O projeto propõe que o usuário escolha uma empresa de referência para que o algoritmo identifique organizações com perfis operacionais e estruturais análogos. Para garantir a utilidade prática da ferramenta, serão implementados filtros parametrizáveis que permitem restringir o escopo das recomendações por abrangência geográfica (municípios, estados ou país) e segmentação de porte (Microempresas, médio ou grande porte).

1.4.1. OBJETIVO GERAL

Desenvolver um sistema de recomendação de empresas B2B fundamentado em análise de similaridade para que se identifiquem organizações com perfis operacionais e estruturais análogos a uma empresa de referência.

1.4.2. OBJETIVO ESPECIFICO

- Coletar e tratar dados estruturados e semiestruturados provenientes da base de "Dados Abertos" do Governo Federal para que se componha um ecossistema de informações confiável entre os anos de 2021 e 2026;
- Implementar algoritmos de filtragem de informação, como K-Nearest Neighbors (KNN) e Cosine Similarity, para que se avalie qual métrica de distância melhor representa a similaridade em dados cadastrais empresariais;
- Desenvolver filtros parametrizáveis de abrangência geográfica e segmentação de porte para que o usuário restrinja o escopo das recomendações conforme sua necessidade estratégica de mercado;
- Validar a eficácia do sistema por meio de uma Prova de Conceito (PoC) para que se comprove a viabilidade técnica e a precisão da solução proposta;
- Estruturar um sistema de pontuação (scoring) com pesos variáveis para que se hierarquize a relevância dos leads gerados para o usuário final, consolidando uma solução de inteligência de mercado.

1.5. DATASET

Segue algumas informações que já temos da base de dados:

Dataset: Cadastro Nacional da Pessoa Jurídica (CNPJ)

Tipo de Arquivo: CSV e PDF

Origem dos Dados: Ministérios da Fazenda / Governo Federal

Sensibilidade: Dados públicos com informações cadastrais das pessoas jurídicas e outras entidades de interesse das administrações tributárias da União, dos Estados, do Distrito Federal e dos Municípios.

Validade: Dados coletados de dezembro de 2021 até 2026

Proprietário dos Dados: Ministérios da Fazenda / Governo Federal

Para atributo dos dados verifique o anexo 1

Para esse tipo de demanda fica claro que a melhor opção é a base de dados em texto. Inicialmente usaremos a base de dados pública do ministério da fazenda do programa “Dados Abertos”.

<https://dados.gov.br/dados/conjuntos-dados/cadastro-nacional-da-pessoa-juridica---cnpj>

Essa base de dados recebe atualizações mensais e portanto muito ampla e vasta para nossas análises.

2. DEFINIÇÃO DO GRUPO DE TRABALHO

Formamos um grupo de trabalho multidisciplinar onde algumas pessoas já possuem conhecimentos prévios de tecnologia. Essa sinergia é muito benéfica pois os integrantes se completam em termos de conhecimentos e habilidades e podem trocar experiências e conhecimento.

- GUSTAVO AZEVEDO GOMYDE - RA:10424543
- RICARDO DE OLIVEIRA VIEIRA FRANCO – RA:10720675

3. REFERENCIAL TEÓRICO

Durante nossas pesquisas encontramos dois algoritmos que poderiam ser úteis para essa demanda: KNN e Similaridade de Cosseno.

Inicialmente faríamos duas POC's para testar qual dos algoritmos é mais adequado, mas gastamos muito tempo ajustando a base de dados pública, que veio com muitos campos "NaN", e tabelas separadas, numa estrutura bastante bagunçada. Logo não teríamos tempo de arrumar a base para rodar cada um dos algoritmos e então decidimos fazer uma pesquisa e focar em apenas um dos algoritmos para esse caso de uso.

Característica	K-Nearest Neighbors (KNN)	Similaridade de Cosseno
Foco da Medida	Distância (Espaço): Mede quão "perto" um ponto está do outro em linha reta.	Ângulo (Direção): Mede se os vetores apontam para a mesma direção, ignorando o tamanho.
Magnitude	Crucial: Diferencia uma empresa de R\$ 10k de capital social de uma de R\$ 1M.	Irrelevante: Se as proporções forem iguais, ele entende que são "iguais".
Tipo de Dado	Ideal para variáveis numéricas e estruturadas (tabelas).	Ideal para textos (NLP) e frequências de palavras.
Sensibilidade	Sensível a outliers (exige normalização).	Robusto a variações de escala, mas perde a noção de "porte".

Tabela 1 – Comparações entre KNN e Similaridade de Cosseno.

A opção pelo KNN em detrimento da Similaridade de Cosseno justifica-se pela natureza dos dados cadastrais. Enquanto o Cosseno prioriza a orientação dos vetores — sendo mais indicado para mineração de textos —, o KNN utiliza a métrica de distância euclidiana, que preserva a importância da magnitude das variáveis. Em um cenário B2B, a escala (como o capital social e o porte) é um diferencial crítico de similaridade que não pode ser descartado pela normalização angular.

Um pequeno artigo da Medium.com mostra muito essa questão da magnitude.

<https://medium.com/@szaranger/cosine-similarity-vs-euclidean-distance-the-one-explanation-every-data-scientist-needs-2acf3337d49e>

3.1. FUNDAMENTAÇÃO TEÓRICA: A PERSPECTIVA DE AMARASINGHE (2025) SOBRE MÉTRICAS DE VETORES

A escolha do algoritmo de recomendação para este projeto não se baseia apenas na popularidade técnica, mas na distinção semântica entre direção e distância, conforme analisado por Amarasinghe (2025). Ao confrontar a Similaridade de Cosseno com a Distância Euclidiana (base do KNN), o autor estabelece critérios claros de aplicação que justificam a estrutura deste sistema B2B.

3.2. A INSUFICIÊNCIA DA DIREÇÃO (COSSENO)

Segundo a interpretação de Amarasinghe, a Similaridade de Cosseno preocupa-se primordialmente com a orientação dos vetores: "Are these vectors pointing in the same direction?". Para o contexto de dados do CNPJ, essa abordagem apresenta uma limitação crítica: ela ignora a magnitude.

No mercado B2B, duas empresas podem compartilhar a mesma "direção" (mesmo setor econômico/CNAE), mas possuírem escalas operacionais opostas. Amarasinghe (2025) adverte que o Cosseno considera vetores de tamanhos diferentes como similares se o ângulo entre eles for zero. Para este trabalho, isso significaria sugerir erroneamente uma multinacional para um usuário que busca uma microempresa, apenas pela coincidência do ramo de atividade.

3.3. A PRIMAZIA DA MAGNITUDE (EUCLIDIANA/KNN)

Em contrapartida, a aplicação da Distância Euclidiana proposta neste estudo alinha-se à tese de que, em certos domínios, "magnitude matters a lot" (Amarasinghe, 2025). Ao medir a distância em linha reta entre os pontos no espaço n-dimensional, o algoritmo KNN captura tanto a direção quanto o módulo (tamanho) das variáveis.

Esta característica é fundamental para o sucesso da prospecção preditiva aqui proposta, pois garante que:

O Porte seja preservado: Empresas com capitais sociais e quadros de funcionários discrepantes estarão "geometricamente distantes", mesmo que operem no mesmo setor.

A Localização seja fidedigna: A distância física entre municípios e estados é uma grandeza absoluta que exige a precisão espacial da métrica euclidiana.

3.4. SÍNTESE INTERPRETATIVA

Conclui-se, através da ótica de Amarasinghe, que a Similaridade de Cosseno, embora dominante em Processamento de Linguagem Natural (NLP), é insuficiente para a recomendação de leads estruturados. A Distância Euclidiana, por ser sensível à escala, permite que o sistema entregue clusters de oportunidades que são, de fato, "vizinhos" em termos de capacidade financeira e operacional, atendendo ao rigor estratégico do mercado Business-to-Business.

4. PROVA DE CONCEITO

Como justificado anteriormente no referencial teórico a prova de conceito foi feita somente para o algoritmo KNN.

A base de dados é muito grande para ser manipulada dentro do jupyter notebook em plataforma cloud, portanto usamos o VSCode linkado ao Jupiter para executar a POC no PC e não na plataforma cloud.

Estamos analisando uma forma de talvez usar uma parte menor do banco de dados, por exemplo somente empresas da região sudeste para permitir que o acesso esteja on-line.

4.1. DEFINIÇÃO DAS BIBLIOTECAS PYTHON

Essas foram as bibliotecas necessária para fazer análise exploratória, tratamento dos dados e prova de conceito (POC).

- Pandas
- Scikit-Learn
- Matplotlib
- Seaborn
- PySpark

Além dessas bibliotecas tivemos alguns pacotes de dependencia para montar o ambiente:

- Java JDK 17 (Necessário para o Spark funcionar);
- Winutils/Hadoop Binaries (Necessário para rodar Spark no Windows).

Cada biblioteca cumpre um papel estratégico no fluxo de Ciência de Dados do sistema de recomendação:

- Pandas: É a biblioteca principal para manipulação de dados tabulares (DataFrames).
 - Relevância: No projeto, ela é usada para carregar os arquivos CSV, filtrar empresas por situação cadastral e preparar a tabela final que o modelo KNN vai consumir. É o "canivete suíço" para limpar e organizar os dados antes da análise.
- PySpark: Interface para o Apache Spark, focada em processamento de grandes volumes de dados (Big Data) de forma distribuída.
 - Relevância: Como a base de dados de CNPJs da Receita Federal é massiva (milhões de linhas), o Spark é usado no primeiro arquivo para realizar os joins (cruzamentos) entre as tabelas de Estabelecimentos e Empresas de forma performática, algo que o Pandas comum teve dificuldade em processar sozinho devido à limitação de memória.
- Scikit-Learn: Biblioteca padrão para Machine Learning em Python.
 - Relevância: Utiliza o NearestNeighbors para calcular a proximidade entre as empresas e o StandardScaler para normalizar os dados (garantindo que a UF e o Porte tenham o mesmo peso matemático na distância).

- Matplotlib & Seaborn: Bibliotecas de visualização de dados. O Seaborn é construído sobre o Matplotlib e oferece gráficos estatísticos mais atraentes.
 - Relevância: Elas transformam os números brutos em informação visual. São usadas para criar os gráficos de barras que mostram a representatividade de empresas por país, facilitando a interpretação dos resultados do modelo para um usuário final ou stakeholder.
- OS e Sys (Nativas do Python): Manipulação de variáveis de ambiente e caminhos do sistema.
 - Relevância: Cruciais no script para apontar onde o Java e o Hadoop estão instalados, garantindo que o Spark consiga inicializar corretamente no ambiente Windows.

4.2. ANÁLISE EXPLORATORIA DA BASE DE DADOS

A base de dados utilizada possui 8 arquivos distintos do tipo CSV que estão organizados conforme o documento “cnpj-metadados.pdf” que se encontra no “ANEXO A” desse artigo acadêmico.

Name	Date modified	Type	Size
Cnaes	3/7/2026 12:32 PM	File folder	
Empresas1	3/7/2026 12:33 PM	File folder	
Estabelecimentos1	3/1/2025 10:02 AM	File folder	
Motivos	3/1/2025 10:03 AM	File folder	
Municipios	3/1/2025 10:03 AM	File folder	
Naturezas	3/1/2025 10:03 AM	File folder	
Países	3/1/2025 10:03 AM	File folder	
Simples	3/1/2025 10:04 AM	File folder	
cnpj-metadados.pdf	3/7/2026 12:36 PM	Adobe Acrobat D...	58 KB

Figura 1 - Organização dos arquivos de metadados da base de CNPJ da receita federal

Acumulando aproximadamente 4GB de informações.




Figura 2 - Tamanho da base de dados

Não esperávamos que a base estivesse tão distribuída, pois para conseguir o nome de uma empresa e sua localização (endereço) é necessário fazer um Join entre tabelas.

Outra dificuldade foi para a codificação das tabelas, diferentes tabelas foram usadas diferentes codificações, claramente vemos que se trata de uma base orgânica, que teve evolução ao longo do tempo e possui algumas definições legadas em algumas tabelas.

Então em nossa análise exploratória primeiro definimos quais tabelas são realmente relevantes para nós.




Figura 3 - Base de dados da receita federal

Pois essas tabelas tem a informações que nos é relevante para atingir o objetivo específico de “Filtros” com a localização da empresa, o tipo de atividade econômica e o porte da empresa.

Após esse processo foi feita a importação da base de dados.

```

# IMPORTANDO A BASE DE ESTABELECIMENTOS
#
cols_estabelecimentos = [
    "CNPJ_BASICO",
    "CNPJ_ORDEM",
    "CNPJ_DV",
    "IDENTIFICADOR_MATRIZ_FILIAL",
    "NOME_FANTASIA",
    "SITUACAO_CADASTRAL",
    "DATA_SITUACAO_CADASTRAL",
    "MOTIVO_SITUACAO_CADASTRAL",
    "NOME_CIDADE_EXTERIOR",
    "PAIS",
    "DATA_INICIO_ATIVIDADE",
    "CNAE_FISCAL_PRINCIPAL",
    "CNAE_FISCAL_SECUNDARIA",
    "TIPO_LOGRADOURO",
    "LOGRADOURO",
    "NUMERO",
    "COMPLEMENTO",
    "BAIRRO",
    "CEP",
    "UF",
    "MUNICIPIO",
    "DDD_1",
    "TELEFONE_1",
    "DDD_2",
    "TELEFONE_2",
    "DDD_FAX",
    "FAX",
    "CORREIO_ELETRONICO",
    "SITUACAO_ESPECIAL",
    "DATA_SITUACAO_ESPECIAL"
]
32.4s

```

Figura 4 - Importação e início da análise exploratória

Foi necessário criar os cabeçalhos pois os arquivos não possuíam nenhum cabeçalho. Portanto o anexo A é essencial para classificar as colunas

Outra dificuldade que tivemos com essa base de dados foram as codificações, que não obedecem o padrão “utf8”, e diferentes tabelas estavam com diferentes codificações, no exemplo abaixo usamos encoding “latin1”.

Também percebemos que muitos registros estavam com valores “nulos” vazios, que já indicava que a base precisaria de um tratamento robusto antes de iniciar a POC.

```

ESTABELECIMENTOS = pd.read_csv(r"C:\Users\welli\OneDrive\Documents\RICARDO\K3241.K03200Y1.D50208.ESTABELE",
    sep=";",
    encoding="latin1",
    names=cols_estabelecimentos
)

display(ESTABELECIMENTOS.head(10))

```

32.4s Python

C:\Users\welli\AppData\Local\Temp\ipykernel_5740\1193448741.py:36: DtypeWarning: Columns (0: NOME_CIDADE_EXTERIOR, 1: DDD_1, 2: TELEFONE_1, 3: TEI) have mixed dtype: object, int64

```

ESTABELECIMENTOS = pd.read_csv(r"C:\Users\welli\OneDrive\Documents\RICARDO\K3241.K03200Y1.D50208.ESTABELE",

```

	CNPJ_BASICO	CNPJ_ORDEM	CNPJ_DV	IDENTIFICADOR_MATRIZ_FILIAL	NOME_FANTASIA	SITUACAO_CADASTRAL	DATA_SITUACAO_CADASTRAL	MOTIVO
0	7396865	1	68	1	NaN	8	20170210	
1	64904295	18	51	2	NaN	8	20161110	
2	76016369	3	16	2	NaN	4	20231113	
3	52302726	1	82	1	NaN	4	20210406	
4	7396923	1	53	1	NaN	8	20140115	
5	3650261	1	45	1	OTICA PERFEICAO	4	20190322	
6	7396929	1	20	1	NaN	3	20111107	
7	25040718	1	32	1	COOCULTURA LTDA	8	20050523	

Figura 5- Análise dos primeiros registros nulos e codificação da base

E isso se repete nas três tabelas

```

# display(ESTABELECIMENTOS[["CODIGO"]].sort_values(by="DESCRIC")
# display(ESTABELECIMENTOS[ESTABELECIMENTOS["PAIS"] == 105])

ESTABELECIMENTOS[["CNAE_FISCAL_PRINCIPAL", "PAIS_INT", "DS_PAIS"]].sort_values(by="PAIS_INT", ascending=False)

```

0.5s Python

	CNPJ_BASICO	CNPJ_ORDEM	CNPJ_DV	IDENTIFICADOR_MATRIZ_FILIAL	NOME_FANTASIA	SITUACAO_CADASTRAL	DATA_SITUACAO_CADASTRAL	MOTIVO
375687	6069133	1	9	1	CARGOLUX	2		0
572386	4705242	1	31	1	NaN	2	20010801	
683297	4864734	1	70	1	NaN	2	19891123	
720070	7100754	1	62	1	ALTO COMISSARIADO DAS NACOES UNIDAS PARA REFUG...	2	20040607	
1175584	7451329	1	18	1	CONSULADO DO SURINAME EM SAO PAULO	2	20050616	
...	...	...	...	...	...	...	...	...
4742427	41955264	1	86	1	PC CONTABILIDADE	2	20210514	

```

testttttt = pd.read_csv(r"C:\Users\welli\OneDrive\Documents\RICARDO\F.K03200$Z.D50208.PAISCsv",
    sep=".",
    encoding="cp1252",
    header=None,
    names=cols_paises
)

# df2 = spark.createDataFrame(PAISEES)

display(testttttt[["CODIGO", "DESCRICAO"]].sort_values(by="DESCRICAO").head(50))


```

0.0s

	CODIGO	DESCRICAO
1	13	AFEGANISTAO
211	756	AFRICA DO SUL
2	17	ALBANIA
3	20	ALBORAN-PEREJIL,ILHAS
4	23	ALEMANHA

Figura 6 - Diferentes tabelas com diferentes codificações

Também fizemos uma análise de quantos registros temos na maior tabela (de estabelecimentos)



```
# EMPRESAS[["CNPJ_BASIC0", "RAZAO_SOCIAL"]].sort_values(by="CNPJ_BASIC0", ascending=False)

# EMPRESAS["CNPJ_BASIC0"] == 1
# display(EMPRESAS[EMPRESAS["CNPJ_BASIC0"] == 3744126])
EMPRESAS.shape
ESTABELECIMENTOS.shape
```

[76] ✓ 0.0s

(4753435, 30)

Figura 7- Fim da análise exploratória

São mais de quatro milhões e setecentos mil registros ativos, nesse cadastro não temos a categoria MEI (microempreendedor individual), pois nosso alvo são empresas com capacidade para fazer importações e compras em um certo volume.

O MEI é uma importante categoria para proteção social do empreendedor individual, mas é focada geralmente em atividades operacionais, comerciais ou de serviços braçais, prestação de serviço não intelectual.

4.3. PREPARAÇÃO DA BASE DE DADOS

A primeira etapa do tratamento é remover registros nulos e ajustar suas colunas, remover espaços vazios e tratar os campos “NaN”.

```
import pandas as pd

# --- 1. PREPARAR TABELA PAISEES ---
# Limpeza radical: converte para string, tira decimais, tira espaços e volta para int
PAISEES_FIX = PAISEES.copy()
PAISEES_FIX["CODIGO_CLEAN"] = (
    PAISEES_FIX["CODIGO"]
    .astype(str)
    .str.replace(r'\.0$', '', regex=True) # Remove .0 no final
    .str.strip() # Remove espaços
)
# Converte para numérico e preenche falhas com 0 antes do int64
PAISEES_FIX["CODIGO_CLEAN"] = pd.to_numeric(PAISEES_FIX["CODIGO_CLEAN"], errors='coerce').fillna(0).astype('int64')

# --- 2. PREPARAR TABELA ESTABELECIMENTOS ---
ESTAB_FIX = ESTABELECIMENTOS.copy()
# Tratamento idêntico ao da tabela de países para garantir o 'match'
ESTAB_FIX["PAIS_JOIN"] = (
    ESTAB_FIX["PAIS"]
    .astype(str)
    .str.replace(r'\.0$', '', regex=True) # Remove .0 no final
    .str.replace(r',0$', '', regex=True) # Remove ,0 no final
    .str.strip() # Remove espaços
    .replace(['nan', 'None', ''], '0') # Trata vazios
)
ESTAB_FIX["PAIS_JOIN"] = pd.to_numeric(ESTAB_FIX["PAIS_JOIN"], errors="coerce").fillna(0).astype('int64')

# --- 3. MERGE SIMPLES (ESTABELECIMENTOS + PAISEES) ---
# Usamos how="inner" se você quiser APENAS quem tem país relacionado,
# ou how="left" para manter todos os estabelecimentos mesmo sem país.
```

Figura 8- Tratamento dos valores nulos

Depois faremos um “Merge” ou “Join”, para ter todos os registros juntos.

```
# --- 3. MERGE SIMPLES (ESTABELECIMENTOS + PAISEES) ---
# Usamos how="inner" se você quiser APENAS quem tem país relacionado,
# ou how="left" para manter todos os estabelecimentos mesmo sem país.
teste = ESTAB_FIX.merge(
    PAISEES_FIX[["CODIGO_CLEAN", "DESCRICAO"]],
    how="left",
    left_on="PAIS_JOIN",
    right_on="CODIGO_CLEAN"
```

Figura 9 - Merge inicial

Depois fizemos uma verificação para saber se o Merge foi realizado com sucesso. Fizemos o “Join” apenas com a tabela estabelecimentos e nos trouxe os resultados com o país 105 (EUA).

```
# --- 4. VERIFICAÇÃO ---
# Vamos checar se o 105 agora encontrou o nome do país
print("Amostra de dados com código 105:")
display(teste[teste["PAIS_JOIN"] == 105][["CNPJ_BASICO", "PAIS_JOIN", "DS_PAIS"]].head())
```

✓ 9.5s

Amostra de dados com código 105:

	CNPJ_BASICO	PAIS_JOIN	DS_PAIS
375687	6069133	105	BRASIL
572386	4705242	105	BRASIL
683297	4864734	105	BRASIL
720070	7100754	105	BRASIL
1175584	7451329	105	BRASIL

Figura 10 - Verificação e validação após merge

Como o resultado foi satisfatório, fizemos o merge com todas as 3 tabelas

```
import pandas as pd

# --- 1. PREPARAR TABELA PAISEES ---
PAISEES_FIX = PAISEES.copy()
PAISEES_FIX["CODIGO_CLEAN"] = (
    PAISEES_FIX["CODIGO"]
    .astype(str)
    .str.replace(r'\.0$', '', regex=True)
    .str.strip()
)
PAISEES_FIX["CODIGO_CLEAN"] = pd.to_numeric(PAISEES_FIX["CODIGO_CLEAN"], errors='coerce').fillna(0).astype('int64')

# --- 2. PREPARAR TABELA ESTABELECIMENTOS ---
ESTAB_FIX = ESTABELECIMENTOS.copy()
ESTAB_FIX["PAIS_JOIN"] = (
    ESTAB_FIX["PAIS"]
    .astype(str)
    .str.replace(r'\.0$', '', regex=True)
    .str.replace(r'\.0$', '', regex=True)
    .str.strip()
    .replace(['nan', 'None', ''], '0')
)
ESTAB_FIX["PAIS_JOIN"] = pd.to_numeric(ESTAB_FIX["PAIS_JOIN"], errors="coerce").fillna(0).astype('int64')

# --- 3. MERGE ESTABELECIMENTOS + PAISEES ---
teste = ESTAB_FIX.merge(
    PAISEES_FIX[["CODIGO_CLEAN", "DESCRICAO"]],
    how="left",
    left_on="PAIS_JOIN",
    right_on="CODIGO_CLEAN"
)
```

Figura 11 - Merge final de todas as tabelas

4.4. DEFINIÇÃO DA TÉCNICA DE TREINAMENTO

Abordagem de Aprendizagem de Máquina

O sistema de recomendação desenvolvido fundamenta-se no paradigma de Aprendizagem de Máquina Supervisionada, com foco específico em tarefas de filtragem baseada em conteúdo e recuperação de informação por similaridade.

A arquitetura do modelo utiliza o algoritmo K-Nearest Neighbors (KNN), ou K-Vizinhos Mais Próximos como motor de inferência principal.

Fundamentação do Algoritmo KNN

KNN é um algoritmo não-paramétrico baseado em instâncias que opera através do cálculo de métricas de proximidade num espaço vetorial multidimensional. No contexto deste projeto, o algoritmo não estabelece uma função discriminante fixa, mas sim armazena os perfis corporativos e identifica os vizinhos com a menor distância euclidiana em relação a um perfil de referência (empresa-alvo). Esta abordagem é particularmente eficaz para sistemas de recomendação B2B, onde a similaridade estrutural define a relevância da sugestão.

Pré-processamento e Engenharia de Atributos (Feature Engineering)

A eficácia do treino e a convergência do modelo são garantidas por etapas rigorosas de tratamento de dados:

- **Normalização Estocástica (StandardScaler):** Dada a sensibilidade do KNN à magnitude das variáveis, foi aplicada a técnica de escalonamento padrão. Esta transforma as variáveis para uma distribuição com média zero e variância unitária, impedindo que atributos com escalas numéricas superiores (como códigos de UF) sobreponham atributos de menor escala (como porte empresarial);
- **Seleção de Preditores:** O modelo é treinado sobre um subconjunto de variáveis críticas que definem a identidade operacional das organizações: a localização geográfica (UF) e a dimensão institucional (PORTE_EMPRESA).

Implementação e Infraestrutura de Dados

A implementação técnica é suportada pelo ecossistema Scikit-Learn, onde o treino é evidenciado pelo método `".fit(X_scaled)"`. Esta etapa consolida a estrutura de dados necessária para a fase de inferência, executada via método `".kneighbors()"`.


Adicionalmente, o pipeline de dados integra o Apache Spark (PySpark) para a fase de ETL (Extract, Transform, Load). Esta escolha tecnológica justifica-se pela volumetria dos dados de Cadastro Nacional da Pessoa Jurídica (CNPJ), permitindo o processamento distribuído de grandes volumes de informação antes da fase de modelagem, garantindo a escalabilidade da solução proposta.

4.5. TREINAMENTO DO MODELO

Preparação dos Dados (Escalonamento)

Antes de treinar, o código ajusta a escala dos dados. Sem isso, o modelo KNN não funciona corretamente.

Em evidência as linhas de treinamento onde o modelo irá “aprender” a posição de cada empresa no mapa de dados.



```
codigo.ipynb • teste2.ipynb • teste.ipynb •
teste2.ipynb > # =====
Generate + Code + Markdown | Run All | Restart | Clear All Outputs | Jupyter Variables |
>
pais_str = str(pais_codigo)
cnae_str = str(cnae_codigo)

# Filtro usando as colunas que agora estão no 'teste'
mask_pais = df_pandas["PAIS_INT"] == pais_codigo
mask_cnae = (df_pandas["CNAE_FISCAL_PRINCIPAL"].str.contains(cnae_str)) | \
            (df_pandas["CNAE_FISCAL_SECUNDARIA"].str.contains(cnae_str))

pdf = df_pandas[mask_pais & mask_cnae].copy()

if pdf.empty:
    return "Nenhuma empresa encontrada para os critérios."

# Transformando UF em número para o KNN entender localização
le = LabelEncoder()
pdf["UF_INDEX"] = le.fit_transform(pdf["UF"])

# Features: Porte e Localização (UF)
features = ["PORTE_EMPRESA", "UF_INDEX"]
X = pdf[features].apply(pd.to_numeric, errors="coerce").fillna(0)

# Normalização
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

# KNN
n_vizinhos = min(n_neighbors, len(pdf))
knn = NearestNeighbors(n_neighbors=n_vizinhos, metric='euclidean')
knn.fit(X_scaled)

distances, indices = knn.kneighbors([X_scaled[0]])

res = pdf.iloc[indices[0]].copy()
res['DISTANCIA_KNN'] = distances[0]
```

Figura 12 - Preparação e treinamento de modelo

Realizamos a primeira busca filtrando código de Pais e CNAE

```
# Teste prático
resultado = knn_empresas_final(teste, pais_codigo=249, cnae_codigo=9900800)
display(resultado)
```

✓ 0.0s

CNPJ BASICO		RAZAO SOCIAL	NOME FANTASIA	DS PAIS	PORTE EMPRESA
157663	3744126	FUNDO DAS NACOES UNIDAS PARA A INFANCIA	UNICEF	ESTADOS UNIDOS	5.0
295672	4164705	SECRETARIA-GERAL DA ORGANIZACAO DOS ESTADOS AM...	SECRETARIA-GERAL DA OEA-RIO	ESTADOS UNIDOS	5.0
1369638	4141058	CONSULADO GERAL AMERICANO NO RIO DE JANEIRO	CONSULADO AMERICANO	ESTADOS UNIDOS	5.0
280975	4122709	CONSULADO GERAL DOS ESTADOS UNIDOS DA AMERICA ...	CONSULADO AMERICANO	ESTADOS UNIDOS	5.0

Figura 13 - Teste após treinamento

E com isso ele trouxe empresas relacionadas, validando que o treinamento funcionou ele trouxe empresas do mesmo ramo de atividade.

4.6. AVALIAÇÃO DE DESEMPENHO

Depois de treinado rodamos o algoritmo cruzando dados de porte da empresa e localização

```
Generate + Code + Markdown | Run All | Restart | Clear All Outputs | Jupyter Variables | Outline | ...
# Visualização
plt.figure(figsize=(10, 5))
sns.scatterplot(data=resultado, x="UF", y="PORTE_EMPRESA",
               hue="DISTANCIA_KNN", size="DISTANCIA_KNN", sizes=(100, 400))
plt.title("Visualização de Proximidade das Empresas")
plt.show()

display(resultado[["RAZAO_SOCIAL", "UF", "PORTE_EMPRESA", "DISTANCIA_KNN"]])
else:
    print(resultado)
```

[84] ✓ 1.6s

Figura 14 - Testando o modelo com dois filtros, porte e localização.

Depois de rodar o modelo tivemos uma assertividade com similaridade próximo aos 71,72%




Figura 15 - Resultado da primeira POC

Em novo teste fizemos uma busca apenas pelo porte da empresa, independentemente de sua localização.

```
# --- EXECUÇÃO E NOVO GRÁFICO ---
resultado = knn_empresas_final(teste, pais_codigo=249, cnae_codigo=9900800)

if isinstance(resultado, pd.DataFrame):
    # Gráfico focado no Porte e Distância
    plt.figure(figsize=(10, 5))
    # Usamos o índice no eixo x apenas para espalhar os pontos visualmente
    sns.scatterplot(data=resultado, x=resultado.index, y="PORTE_EMPRESA",
                    hue="DISTANCIA_KNN", size="DISTANCIA_KNN", sizes=(100, 400), palette="viridis")

    plt.title("KNN: Similaridade Baseada Apenas no Porte (Ignorando UF)")
    plt.xlabel("ID do Registro")
    plt.ylabel("Porte da Empresa")
    plt.show()

    display(resultado[["RAZAO_SOCIAL", "UF", "PORTE_EMPRESA", "DISTANCIA_KNN"]])
else:
    print(resultado)
```

Figura 16 - Testando o modelo somente com porte da empresa

E aqui mostra quantas empresas são relacionadas a um tipo de atividade específica.




Figura 17 - Resultado segundo teste

Em outro teste, buscamos empresas que sejam dos EUA e estejam com unidade fiscal aberta no Brasil e sejam relacionadas a um determinado CNAE.

```
# --- EXECUÇÃO DO MODELO ---
pais_alvo = 249
cnae_alvo = 9900800
n_vizinhos_desejados = 10 # Defina quantos vizinhos quer buscar

resultado = knn_empresas_final(teste, pais_codigo=pais_alvo, cnae_codigo=cnae_alvo, n_neighbors=n_vizinhos_desejados)

if isinstance(resultado, pd.DataFrame):
    # 1. CÁLCULO PARA O GRÁFICO DE BARRAS
    coluna_pais = "PAIS_JOIN" if "PAIS_JOIN" in teste.columns else "PAIS_INT"

    total_pais = len(teste[teste[coluna_pais] == pais_alvo])
    total_encontrado = len(resultado)
    nome_pais = resultado["DS_PAIS"].iloc[0] if "DS_PAIS" in resultado.columns else f"País {pais_alvo}"

    # 2. CRIANDO O GRÁFICO DE BARRAS COMPARATIVO
    plt.figure(figsize=(8, 6))
    categorias = ['Total no País', 'Relacionadas (KNN)']
    valores = [total_pais, total_encontrado]

    barras = plt.bar(categorias, valores, color=["#0c0e0f", '#27ae60'])

    # Adicionar os números em cima das barras
    for barra in barras:
        yval = barra.get_height()
        plt.text(barra.get_x() + barra.get_width()/2, yval + (total_pais*0.01),
                 int(yval), ha='center', va='bottom', fontweight='bold')

    plt.title(f"Representatividade de Empresas - {nome_pais}" fontweight='bold')
    plt.show()
```

Figura 18 - testando empresas estrangeiras relacionados ao CNAE

O algoritmo encontrou um total de 8 empresas com esse critério, mas relacionou 4 delas como sendo próximas, ou seja potenciais alvos com mesmo porte e atividade economia.




Figura 19 - Resultado terceiro teste

5. METODOLOGIA

Nesta seção, é apresentado o desenvolvimento deste trabalho, descrevendo a metodologia utilizada para a execução dos experimentos de recomendação B2B. O esquema geral da metodologia seguiu um fluxo de processamento de Big Data, desde a ingestão da base bruta da Receita Federal até a entrega do ranking de similaridade.




Figura 20 – Fluxograma da metodologia usada

5.1. DEFINIÇÃO DO PROBLEMA E OBJETIVOS

O problema abordado é a ineficiência na prospecção manual de clientes B2B no setor de tecnologia IoT. O objetivo foi construir um motor de recomendação capaz de ranquear empresas similares com base em múltiplas dimensões: segmento (CNAE), porte (Capital Social), localização (UF) e natureza jurídica.

5.2. COLETA DE DADOS

A coleta de dados foi realizada através dos dados abertos do Ministério da Fazenda (Receita Federal). A base é composta por aproximadamente 70 milhões de registros distribuídos em arquivos CSV de Estabelecimentos, Empresas, Sócios e CNAEs, totalizando cerca de 4GB de dados brutos pós-compressão

Desenvolvimento da Base de Dados no formato "Parquet"

1. Armazenamento Inicial

Primeiramente, fizemos o upload dos arquivos brutos para o **Google Drive**, permitindo:

- Persistência dos dados
- Facilidade de acesso no ambiente do Google Colab
- Organização dos arquivos por categoria (Empresas, Estabelecimentos, CNAE)

2. Consolidação da Base de Empresas

Os dados de **Empresas** estavam fragmentados em vários arquivos. O processo foi:

- Leitura de todos os arquivos
- União (append) em uma única base
- Conversão para o formato **Parquet**

Por que usei Parquet?

O formato **Parquet** é ideal para Big Data porque:

- Alta compressão → reduz espaço em disco
- Leitura muito mais rápida que CSV
- Formato colunar → otimiza consultas (lê só as colunas necessárias)
- Integração nativa com Spark

Isso é essencial quando se trabalha com **milhões de linhas**, como neste projeto.

Figura 21 – Setup do Dataset

Após a configuração do Parquet e importação da base de dados, pedimos para visualizar os primeiros 10 registros.

...

	_c0	_c1	_c2	_c3	_c4	_c5	_c6
	41273590	MARIA DAS MERCES ...	4014	34	0,00	05	NULL
	41273591	CASSIO APARECIDO ...	2135	50	1000,00	01	NULL
	41273592	41.273.592 HELIO ...	2135	50	30000,00	01	NULL
	41273593	JULIO CESAR NUNES...	2135	50	3000,00	01	NULL
	41273594	OZINETE DELFINO C...	2135	50	5000,00	01	NULL
	41273595	GILVAN PEREIRA XA...	2135	50	3000,00	01	NULL
	41273596	RODRIGO JOSE FERR...	2135	50	10000,00	01	NULL
	41273597	PACHARRUS QUEIROZ...	2135	50	5000,00	01	NULL
	41273598	GLORIA VIANA DIAS...	2135	50	1100,00	01	NULL
	41273599	ANA PAULA DA SILV...	2135	50	2000,00	01	NULL

only showing top 10 rows

Figura 22 – Primeira Visualização do Dataset

Como a base dados não possui cabeçalho então as colunas estão nomeadas de forma genérica “_c0” até “_c6”.

Para facilitar e preparar os dados para a etapa de pré-processamento, já incluímos os cabeçalhos, conforme o código abaixo e seu respectivo output.

```
df_empresas = df_final.toDF(
    "CNPJ_BASICO",
    "RAZAO_SOCIAL",
    "NATUREZA_JURIDICA",
    "QUALIFICACAO_RESPONSAVEL",
    "CAPITAL_SOCIAL",
    "PORTE_EMPRESA",
    "ENTE_FEDERATIVO"
)
```

```
df_empresas.show(10)
df_empresas.printSchema()
```

```
+-----+-----+-----+-----+-----+-----+-----+
|CNPJ_BASICO|RAZAO_SOCIAL|NATUREZA_JURIDICA|QUALIFICACAO_RESPONSAVEL|CAPITAL_SOCIAL|PORTE_EMPRESA|ENTE_FEDERATIVO|
+-----+-----+-----+-----+-----+-----+-----+
|41273590|MARIA DAS MERCES ...|4014|34|0,00|05|NULL|
|41273591|CASSIO APARECIDO ...|2135|50|1000,00|01|NULL|
|41273592|41.273.592 HELIO ...|2135|50|3000,00|01|NULL|
|41273593|JULIO CESAR NUNES...|2135|50|3000,00|01|NULL|
|41273594|OZINETE DELFINO C...|2135|50|5000,00|01|NULL|
|41273595|GILVAN PEREIRA XA...|2135|50|3000,00|01|NULL|
|41273596|RODRIGO JOSE FERR...|2135|50|10000,00|01|NULL|
|41273597|PACHARRUS QUEIROZ...|2135|50|5000,00|01|NULL|
|41273598|GLORIA VIANA DIAS...|2135|50|1100,00|01|NULL|
|41273599|ANA PAULA DA SILV...|2135|50|2000,00|01|NULL|
+-----+-----+-----+-----+-----+-----+-----+
```

only showing top 10 rows

root

```
-- CNPJ_BASICO: string (nullable = true)
-- RAZAO_SOCIAL: string (nullable = true)
-- NATUREZA_JURIDICA: string (nullable = true)
-- QUALIFICACAO_RESPONSAVEL: string (nullable = true)
-- CAPITAL_SOCIAL: string (nullable = true)
-- PORTE_EMPRESA: string (nullable = true)
-- ENTE_FEDERATIVO: string (nullable = true)
```

Figura 23 – Ajuste do Dataset

Depois repetimos o mesmo para a tabela “estabelecimento” e “CNAE”

```
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|CNPJ_BASICO|CNPJ_ORDEN|CNPJ_DV|MATRIZ_FILIAL|NOME_FANTASIA|SITUACAO_CADASTRAL|DATA_SITUACAO|MOTIVO_SITUACAO|CIDADE_EXTERIOR|PAIS|DATA_INICIO|CNAE_PRINCIPAL|CNAE_SECUNDARIO|TIPO_LOGRADOURO|LOGRADOURO|NU
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
|24479582|0001|05|1|BEL BOLOS|08|20231011|01|NULL|NULL|20160329|1091102|NULL|RUA|CAMPO BELO DO SUL|
|25882432|0001|10|1|NULL|02|20160627|00|NULL|NULL|20160627|4781400|NULL|RUA|GAL. NETO|
|22880216|0001|21|1|NULL|02|20230505|00|NULL|NULL|20150720|4722901|4721103,4712100,4...|AVENIDA|DOUTOR CORREA PINTO|
|23270955|0001|64|1|BERG VARIEDADES|08|20160815|01|NULL|NULL|20150914|4763601|4755502,4781400,4...|QUADRA|QI 15|
|24584233|0001|47|1|NETPRIME|04|20210409|03|NULL|NULL|20160413|4751201|6204000,6311000,9...|RUA|ONZE (VL SOCIAL)|
|22745110|0001|15|1|BILK COLCHOES MAG...|08|20170922|01|NULL|NULL|20150629|4754702|4755503,4759001,4...|RUA|VEREADOR SEVERINO...|
|23854561|0001|53|1|MEAZZA PINTURAS|08|20170804|01|NULL|NULL|20151216|4330404|NULL|RUA|MACHADO DE ASSIS|
|20604150|0001|52|1|NULL|08|20161231|01|NULL|NULL|20160830|9492000|NULL|RUA|VEREADOR JOSE GOMES|
|24442258|0001|80|1|NULL|04|20240808|03|NULL|NULL|20150513|4330404|4330103|RUA|MATEUS SILVA|
|22236369|0001|30|1|LOY PET|02|20150413|00|NULL|NULL|20150413|9609208|4771704,4789004,8...|AVENIDA|SENADOR VERGUEIRO|
+-----+-----+-----+-----+-----+-----+-----+-----+-----+-----+
```

only showing top 10 rows

```
+-----+-----+
|CNAE_CODIGO|CNAE_DESCRICAO|
+-----+-----+
|0321399|Cultivos e semicu...|
|1742701|Fabricação de fra...|
|0210107|Extração de madei...|
|2863100|Fabricação de máq...|
|7490101|Serviços de tradu...|
|0892401|Extração de sal m...|
|1012102|Abate de pequenos...|
|4520002|Serviços de lante...|
|5611203|Lanchonetes, casa...|
|7119704|Serviços de períc...|
+-----+-----+
```

only showing top 10 rows

root

```
-- CNAE_CODIGO: string (nullable = true)
-- CNAE_DESCRICAO: string (nullable = true)
```

Figura 24 – Finalizando ajuste do Dataset

Essa etapa é importante para garantir que conseguimos importar a base de dados para o Google Drive e abrir no Google Colab.

Nesta etapa, os dados foram submetidos a um processo de ETL (Extract, Transform, Load):

- Tratamento de Nulos: Remoção de registros sem atividade econômica definida.
- Feature Engineering: Criação da variável "Idade da Empresa" a partir da data de início de atividades.
- Normalização: Aplicação de StandardScaler nos campos numéricos de Capital Social para evitar que a magnitude dos valores distorcesse o cálculo de distância.
- Vetorização: Uso de TF-IDF para converter as descrições textuais das atividades econômicas (CNAE) em vetores numéricos processáveis.

```
# join
df_base = (
    df_estabelecimentos
    .join(df_empresas, on="CNPJ_BASICO", how="inner")
    .join(df_final_CNAE, df_estabelecimentos["CNAE_PRINCIPAL"] == df_final_CNAE["CNAE_CODIGO"], how="left")
)

df_base = df_base.drop("CNAE_CODIGO")

# salvar em parquet
df_base.write \
    .mode("overwrite") \
    .option("compression", "snappy") \
    .parquet("/content/drive/MyDrive/Notebook Ricardo/base final cnpj")
```

- Figura 25 – Trecho de código para pré-processamento e limpeza dos dados

Foi possível verificar a base pronta.

CNPJ_BASICO	CNPJ_ORDEM	CNPJ_DV	MATRIZ_2	NOME_FANTASIA	SITUACAO_CADASTRAL	DATA_SITUACAO	MOTIVO_SITUACAO	CIDADE_EXTERIOR	PAIS	DATA_INICIO	CNAE_PRINC	
00000075	0001	72	1	NULL		02	20051103	00	NULL	NULL	19810723	945
00000265	0001	90	1	NULL		08	19940723	01	NULL	NULL	19830624	478
00000660	0001	72	1	NULL		04	20181123	63	NULL	NULL	19941287	681
00000683	0001	87	1	NULL		02	20100131	01	NULL	NULL	19941216	615
00000711	0001	66	1	NULL		08	20081231	61	NULL	NULL	19660818	477
00000790	0002	96	2	GEL GALERIA DE EM...		04	20181218	63	NULL	NULL	19940516	781
00000790	0003	77	1	GEL GALERIA DE EM...		04	20181218	63	NULL	NULL	19940706	745
00000790	0001	85	1	GEL GALERIA DE EM...		04	20181218	63	NULL	NULL	19940512	781
00000790	0004	58	2	NULL		04	20181218	63	NULL	NULL	19941021	781
00000793	0001	49	1	CIVILWARE		04	20181004	63	NULL	NULL	19940429	626

```
+-----+-----+
only showing top 10 rows
```

```

root
|-- CNPJ_BASICO: string (nullable = true)
|-- CNPJ_ORDEM: string (nullable = true)
|-- CNPJ_OV: string (nullable = true)
|-- MOTRIZ_FILIAL: string (nullable = true)
|-- NOME_FANTASIA: string (nullable = true)
|-- SITUACAO_CADASTRAL: string (nullable = true)
|-- DATA_SITUACAO: string (nullable = true)
|-- MOTIVO_SITUACAO: string (nullable = true)
|-- CIDADE_EXTERIOR: string (nullable = true)
|-- PAIS: string (nullable = true)
|-- DATA_INICIO: string (nullable = true)
|-- CNAE_PRINCIPAL: string (nullable = true)
|-- CNAE_SECUNDARIO: string (nullable = true)
|-- TIPO_LOGRADOURO: string (nullable = true)
|-- LOGRADOURO: string (nullable = true)
|-- NUMERO: string (nullable = true)
|-- COMPLEMENTO: string (nullable = true)
|-- BAIRRO: string (nullable = true)
|-- CEP: string (nullable = true)
|-- UF: string (nullable = true)
|-- MUNICIPIO: string (nullable = true)
|-- DDD1: string (nullable = true)
|-- TEL1: string (nullable = true)
|-- DDD2: string (nullable = true)
|-- TEL2: string (nullable = true)
|-- DDD_FAX: string (nullable = true)
|-- FAX: string (nullable = true)
|-- EMAIL: string (nullable = true)
|-- SITUACAO_ESPECIAL: string (nullable = true)
|-- DATA_SITUACAO_ESPECIAL: string (nullable = true)
|-- RAZAO_SOCIAL: string (nullable = true)
|-- NATUREZA_JURIDICA: string (nullable = true)
|-- QUALIFICACAO_RESPONSAVEL: string (nullable = true)
|-- CAPITAL_SOCIAL: string (nullable = true)
|-- PORTE_ENTRADA: string (nullable = true)
|-- ENTE_FEDERAL: string (nullable = true)
|-- CNAE_DESCRICAO: string (nullable = true)

```

```

▶ base_final_ric = "/content/drive/MyDrive/Notebook_Ricardo/base_final_cnpj"

df = spark.read.parquet(base_final_ric)
df.show(10)
print(f"Linhas: {df.count()}")
print(f"Colunas: {len(df.columns)}")

```

CNPJ_BASICO	CNPJ_ORDEM	CNPJ_DV	MATRIZ_FILIAL	NOME_FANTASIA	SITUACAO_CADASTRA
00000055	0001	00	1	NULL	0
00000148	0001	26	1	NULL	0
00000230	0001	50	1	NULL	0
00000759	0001	74	1	NULL	0
00000872	0001	50	1	MADEMAX	0
00001084	0001	88	1	EXCLUSIV	0
00001087	0001	11	1	NULL	0
00001398	0001	80	1	NULL	0
00001641	0001	60	1	NULL	0
00001705	0001	23	1	NULL	0

only showing top 10 rows
 Linhas: 70386256
 Colunas: 37

Figura 26 – Visualização da base unificada e pré-processada

Dada a natureza volumosa dos dados (aproximadamente 70 milhões de registros originais), utilizou-se o framework Apache Spark (via PySpark) para processamento distribuído. As etapas incluíram:

Padronização de Formato: Conversão dos dados originais para o formato Parquet. Esta escolha justifica-se pela alta taxa de compressão e eficiência na leitura de colunas específicas, otimizando o tempo de processamento.

Filtragem de Ativos: Visando a integridade das recomendações, a base foi filtrada para conter apenas empresas com situação cadastral "Ativa", reduzindo o volume para cerca de 28 milhões de registros.

```

# Removemos as empresas inativas
df = df.filter(df.SITUACAO_CADASTRAL == "02")
df.show(10)
print(f"Linhas: {df.count()}")
print(f"Colunas: {len(df.columns)}")

```

CNPJ_BASICO	CNPJ_ORDEM	CNPJ_DV	MATRIZ_FILIAL	NOME_FANTASIA	SITUACAO_CADASTRAL	DATA_SITUAC
00002341	0001	04	1	NULL	02	200511
00006453	0001	25	1	NULL	02	200511
00006598	0001	26	1	KIOSKI LANCHES	02	200511
00008909	0001	96	1	VELAS SANT ANNE	02	200511
00011740	0001	23	1	NULL	02	200511
00012846	0001	41	1	NULL	02	200511
00014990	0001	17	1	ATP SAT	02	200511
00015331	0001	03	1	NULL	02	200511
00018449	0001	87	1	ELECTRA MOTEL	02	200511
00020574	0001	21	1	NULL	02	200511

only showing top 10 rows
 Linhas: 28470105
 Colunas: 37

Figura 27 – Dificuldades em manipular tantos registros com recursos limitados do Colab.

Escolhemos fazer isso pois aumentaríamos a qualidade da base de dados ao invés de simplesmente pegar uma amostra.

Mesmo assim a execução no Google Colab ficou muito prejudica, pois a base era muito grande, então fizemos alguns testes isolando entre 1% e 33% da base, e tivemos uma boa performance isolando aleatoriamente 10% da base.

```
...  Lendo base completa...
Total de colunas: 37
=====
[✓] Filtro aplicado (somente empresas ativas)
=====
[✗] Amostra de 10% criada
=====
[📁] Salvando amostra...
✓ Amostra salva em: /content/drive/MyDrive/Notebook_Ricardo/base_amostra_10percent
=====
[📁] Lendo amostra salva...

[📊] BASE FINAL (AMOSTRA 10%)
Total de linhas: 2,847,828
Total de colunas: 37
=====

Schema da base:
-----
CNPJ_BASICO      | StringType()      | nullable=True
CNPJ_ORDEM      | StringType()      | nullable=True
```

Figura 28 – Nova base amostral 10%.

Tratamento de Valores Nulos: Colunas com ausência de dados superior a 99% (ex: Situacao Especial) foram removidas.

```
...  análise completa de qualidade dos dados
=====
```

	Coluna	Total	Problemas	% Problemas
17	SITUACAO_ESPECIAL	2846408	99.95	
18	DATA_SITUACAO_ESPECIAL	2846408	99.95	
1	CIDADE_EXTERIOR	2844035	99.87	
20	ENTE_FEDERATIVO	2839336	99.70	
2	PAIS	2691829	94.52	
15	FAX	2616045	91.86	
14	DDD_FAX	2615887	91.86	
13	TEL2	2526596	88.72	
12	DDD2	2525684	88.69	
0	NOME_FANTASIA	2028664	71.24	
7	COMPLEMENTO	1624845	57.06	
3	CNAE_SECUNDARIO	1153036	40.49	
16	EMAIL	326220	11.46	
11	TEL1	95109	3.34	
10	DDD1	95102	3.34	
4	TIPO_LOGRADOURO	16633	0.58	
9	CEP	7477	0.26	
8	BAIRRO	2834	0.10	
19	PORTE_EMPRESA	310	0.01	
6	NUMERO	81	0.00	
5	LOGRADOURO	42	0.00	

Figura 29 – Limpando a base atual de 10%.

Limpeza Textual: Aplicação de expressões regulares (Regex) e normalização (remoção de acentos e caracteres especiais) para as razões sociais e descrições CNAE.

Tipagem de Dados: Conversão manual de campos financeiros (Capital Social) de string para tipo numérico flutuante para fins estatísticos.

5.4. DIVISÃO DOS DADOS

Para a fase de desenvolvimento, análise exploratória (EDA) e experimentação dos algoritmos, foi extraída uma amostra probabilística estratificada de 10% da base total de empresas ativas, resultando em um subconjunto de aproximadamente 2,84 milhões de registros. Esta técnica permitiu a validação da lógica do algoritmo com menor custo computacional, mantendo a representatividade estatística das variáveis, como a distribuição de Capital Social e Porte Empresa.

Vejamos algumas análises (EDA) da base:



Figura 30 – Este gráfico identifica as atividades econômicas mais frequentes na base

O que diz: O mercado é dominado pelo setor de serviços e varejo de pequeno porte, como "Comércio varejista de artigos de vestuário" e "Cabeleireiros".

Importância para o Modelo: Indica que o sistema de recomendação terá muitos exemplos para aprender similaridades em setores de varejo, mas pode enfrentar maior esparsidade em setores industriais pesados.




Figura 31 – Representa o valor investido nas empresas, utilizando uma escala logarítmica

O que diz: Como a variação de capital entre um microempreendedor e uma grande usina é abismal, a escala logarítmica é usada para "normalizar" a visão. A maioria das empresas concentra-se no centro da curva (o que indica capitais médios padronizados), mas há uma "cauda longa" de empresas com capital altíssimo.

Importância para o Modelo: Justifica a etapa de **StandardScaler** (normalização) mencionada na metodologia, para que o valor bruto do capital não distorça o cálculo de distância do KNN.



Figura 32 – Mostra a evolução temporal da criação de empresas

O que diz: Há um crescimento exponencial na abertura de empresas a partir dos anos 2000, com um pico acentuado nos últimos anos. Isso reflete mudanças na legislação (como a criação do MEI) e a digitalização da economia.

Importância para o Modelo: O tempo de mercado (idade) é uma *feature* de similaridade, empresas criadas no mesmo boom econômico podem ter comportamentos de mercado parecidos.



Figura 33 – Gráfico com todas as empresas ativas

Esse gráfico já era esperado, visto que na etapa de pré-processamento filtramos apenas empresas ativas.

5.5. SELEÇÃO E IMPLIMENTAÇÃO DO ALGORITMO

Foi implementada uma abordagem híbrida:

- K-Nearest Neighbors (KNN): Utilizado para encontrar os vizinhos mais próximos no espaço vetorial de porte e localização.
- Similaridade de Cosseno: Aplicada sobre os vetores TF-IDF para refinar a proximidade semântica entre as atividades econômicas das empresas.

5.6. TREINAMENTO DO MODELO

O treinamento consistiu no ajuste do modelo NearestNeighbors da biblioteca Scikit-Learn, utilizando a métrica de distância euclidiana para variáveis numéricas e o cálculo de similaridade de cosseno para o cruzamento de strings de atividades econômicas. O processamento foi otimizado localmente via VSCode para garantir a manipulação eficiente do volume de dados.

5.7. AVALIAÇÃO DO DESEMPENHO

A avaliação foi planejada com base em métricas de recuperação de informação: Precision@K, Recall@K e MAP (Mean Average Precision). A validação técnica ocorreu através do teste de "Empresa de Referência", onde o sistema deve retornar concorrentes diretos já conhecidos no mercado no topo da lista.

Para garantir o rigor acadêmico, foram aplicadas métricas consagradas em sistemas de informação e recuperação de dados:

- **Precision (Precisão):** Avalia a proporção de recomendações corretas dentro do conjunto de vizinhos retornados.
- **MAP (Mean Average Precision):** Mensura a média das precisões calculadas em diferentes pontos do ranking, penalizando modelos que colocam empresas irrelevantes no topo da lista.
- **NDCG (Normalized Discounted Cumulative Gain):** Avalia a qualidade do ranqueamento baseado na utilidade (ganho) de cada empresa recomendada, considerando sua posição relativa na lista final.
- **Recall (Sensibilidade) por UF e Porte:** Verifica se o modelo foi capaz de manter a consistência geográfica e estrutural dentro do filtro de similaridade.

5.8. OTIMIZAÇÃO E AJUSTE

Durante os testes, identificou-se a necessidade de pesos diferenciados: atribuiu-se maior relevância ao CNAE Principal e ao Capital Social, enquanto a localização (UF) foi tratada como um filtro opcional para permitir recomendações nacionais ou regionais conforme a necessidade do usuário.

Seleção da Arquitetura Híbrida

A otimização mais significativa foi a transição de modelos isolados para uma abordagem **Híbrida**.

- **Ajuste Realizado:** Observou-se que o KNN isolado possuía excelente capacidade de localização espacial, mas perdia precisão na ordenação final por relevância (conforme indicado pelo score inferior de 0.782 na Tabela de Resultados).
- **Otimização:** Integrou-se o KNN para a seleção do conjunto de candidatos (*candidate generation*) com a Similaridade de Cosseno para o ranqueamento refinado. Esse ajuste permitiu que o modelo atingisse o **Score Final de 0.992**, uma melhoria de aproximadamente 26% em relação ao uso isolado do KNN.

Eficiência de Larga Escala e Desempenho Temporal

Um gargalo crítico identificado durante os testes de otimização foi o tempo de processamento de algoritmos baseados em centroides.

- **Diagnóstico:** O gráfico de **Tempo** demonstrou que o algoritmo **K-Means** apresentava uma latência inaceitável para aplicações em tempo real, demandando cerca de **12.46 segundos** por consulta.
- **Solução:** Otimizou-se o pipeline através da redução de dimensionalidade via PCA e indexação via KNN Híbrido, reduzindo o tempo de resposta para **0.08 segundos**. Esta otimização de **150 vezes na velocidade** sem perda de precisão foi o fator decisivo para a viabilidade do projeto.

Refinamento de Atributos e Variância (Insight do PCA)

A otimização envolveu o ajuste fino da retenção de variância no processamento das atividades econômicas.

- **Ajuste do TF-IDF:** Configurou-se o vetorizador para ignorar termos genéricos da base CNAE que causavam colisões de similaridade entre setores distintos.
- **Ajuste do PCA:** Selecionou-se o número de componentes principais que maximizava a variância explicada, permitindo que o modelo processasse vetores mais "leves" sem degradar o **MAP (Mean Average Precision)**, que permaneceu em **1.0** no modelo otimizado.

O processo de ajuste fino demonstrou que a precisão absoluta (1.0) do modelo Híbrido não decorreu apenas da escolha do algoritmo, mas da simbiose entre o pré-processamento otimizado (Parquet/Spark) e a redução eficiente de dimensionalidade. Os gráficos de desempenho temporal validam que as otimizações implementadas tornaram o sistema apto a operar em infraestruturas de Big Data com latência mínima.

5.9. IMPLANTAÇÃO E MONITORAMENTO

O sistema foi concebido como um protótipo funcional em ambiente Python. O monitoramento de desempenho é realizado através do tempo de resposta das consultas (query latency), buscando manter o retorno de recomendações abaixo de 0.1 segundos para garantir a usabilidade em ferramentas de vendas.

Estratégia de Implantação (Interface de Consulta)

A implantação foi projetada para operar de forma modular. O modelo Híbrido, após validado, permite a criação de uma função de consulta que recebe o identificador único de uma empresa (CNPJ) e retorna as "N" organizações com maior score de aderência.

- **Ação Técnica:** O uso de PySpark e Parquet permite que esta consulta seja realizada via SQL ou funções Python, facilitando a integração com *dashboards* ou sistemas de CRM.

Escalabilidade em Produção

Um ponto crítico para a implantação é a capacidade de processar a base completa (70 milhões de registros).

- **Ação Técnica:** Em produção, a implantação utiliza o particionamento de dados do formato Parquet para reduzir a latência de leitura durante o processo de recomendação.

Ciclo de Monitoramento e Retreinamento

Dada a dinâmica do mercado brasileiro, com milhares de aberturas e baixas de empresas mensais (conforme o gráfico de "Abertura por Ano"), o monitoramento é essencial.

- **Diretriz de Monitoramento:** Propõe-se um ciclo de atualização mensal, acompanhando as cargas de dados abertos da Receita Federal. O monitoramento de desempenho deve focar na "deriva de dados" (*data drift*), garantindo que os novos CNAEs e variações de capital social sejam incorporados ao espaço vetorial do modelo sem degradar o **MAP** e o **NDCG**

6. RESULTADOS

a) Métricas de Avaliação

Com base nos testes realizados e documentados no notebook, o modelo híbrido (KNN + Similaridade de Cosseno com TF-IDF) apresentou as seguintes métricas:

Resultado Final:

	Modelo	Precision	Recall_UF	Recall_Porte	MAP	NDCG	Sim	Tempo	Score_Final
1	Híbrido	1.0	1.0	1.0	1.000000	1.000000	0.933495	0.085408	0.992131
2	PCA	0.8	0.4	1.0	0.864435	0.968011	0.976347	0.290950	0.795551
3	KNN	0.8	0.3	1.0	0.864435	0.933462	0.343591	0.182758	0.782454
4	Cosine	0.8	0.3	1.0	0.875546	0.964740	0.960993	0.312458	0.781013
5	KMeans	0.7	0.3	1.0	0.723299	0.839293	0.857068	12.460835	0.632983

- **Precisão (Precision):** 1.0 (100% de relevância nos vizinhos recomendados para os critérios testados).
- **Revocação (Recall):** 1.0 (consistência total na recuperação de empresas por UF e Porte).
- **MAP (Mean Average Precision):** 1.0.
- **NDCG:** 1.0 (indica ordenação perfeita dos resultados com base na utilidade).

Superioridade do Modelo Híbrido: A abordagem Híbrida obteve a pontuação máxima (**1.0**) nas métricas de **Precision**, **Recall**, **MAP** e **NDCG**. Isso indica que o modelo alcançou a ordenação perfeita dos resultados, garantindo que as empresas sugeridas compartilhem integralmente o perfil de porte e localização da empresa de referência.




Figura 34 – Score final para eficiência computacional

Eficiência Computacional (Tempo): Um insight crítico extraído do gráfico de **Tempo** revela que o modelo Híbrido apresenta um custo computacional significativamente menor (**0.08s**) em comparação ao **K-Means**, que demandou **12.46s** por processamento. Dada a escala de 70

milhões de registros da base original, essa eficiência valida a viabilidade de implantação do modelo em tempo real.




Figura 35 – Validação Qualitativa

- Além das métricas quantitativas, o sistema foi submetido a testes de sanidade com empresas âncoras. Observou-se que as recomendações mantiveram a coerência setorial (CNAE) e de capital social, mesmo em setores com alta densidade de registros, como o varejo, o que confirma a eficácia do tratamento TF-IDF aplicado às descrições de atividades.

b) Comparação com Baselines

O sistema híbrido foi confrontado com modelos simplificados:

- **KNN Puro vs. Híbrido:** O modelo híbrido superou o KNN isolado ao mitigar o viés de magnitude do capital social através do refinamento com Similaridade de Cosseno.
- **Clustering (K-Means):** Utilizado como baseline de segmentação, mostrou-se menos eficiente em tempo e precisão direta para recomendações 1-para-1.

c) Gráficos e Visualizações

- **Distribuição por Porte e UF:** Os gráficos abaixo demonstram como o sistema filtra empresas similares.




Figura 36 – Mostra a distribuição geográfica das empresas

- **O que diz:** Há uma concentração maciça no estado de **São Paulo (SP)**, que possui um volume muito superior aos demais estados, seguido por MG, RJ e PR.
- **Importância para o Modelo:** Evidencia a necessidade de considerar a localização como um peso importante, já que a similaridade regional é um forte fator de concorrência.




Figura 37 – Classifica as empresas pelo seu tamanho oficial

- **O que diz:** A vasta maioria das empresas ativas (**80,3%**) são **Microempresas (ME)**. As empresas de grande porte ("Demais") representam apenas 14,2%.
- **Importância para o Modelo:** Reforça que o motor de recomendação deve ser muito preciso ao comparar pequenas empresas entre si, evitando sugerir uma multinacional como similar a um comércio local.

d) Discussão de Resultados

- **Interpretação:** A assertividade de similaridade próxima a **71,72%** no primeiro teste prático valida a capacidade do motor em identificar concorrentes reais.

- **Limitações:** Observou-se a necessidade de processamento local (VSCode + Spark) devido ao volume de 4GB/70 milhões de registros, o que limita a implantação em nuvem gratuita (Google Colab) sem amostragem.
- **Desempenho Geral:** O modelo destacou-se na recomendação setorial (varejo e serviços) devido ao tratamento TF-IDF das atividades econômicas.

Prova de uso

- Realizamos uma busca por uma grande loja do Varejo “Magazine Luiza”

```
=====
🔍 BUSCADOR DE EMPRESAS SIMILARES (modo contínuo)
Digite 'sair' para encerrar
=====

Digite empresa:
[ magazine luiza ]

=====
❌ Empresa não encontrada.

Digite empresa:
[ MAGAZINE LUIZA ]

=====
[ EMPRESA ENCONTRADA: MAGAZINE LUIZA S/A
  UF: SP ]
=====

🔍 TOP RESULTADOS MAIS SEMELHANTES
```

Figura 38 – Usando interface de busca

E o sistema de indicação buscou empresas similares inclusive no porte, não trazendo pequenos mercados varejistas.


```

Digite empresa:
[ JADLOG
]

```

EMPRESA ENCONTRADA: JADLOG LOGISTICA S.A
UF: SP

TOP RESULTADOS MAIS SEMELHANTES

#1 FADEL TRANSPORTES E LOGISTICA LTDA
Score: 0.9965 [■■■■■■■■■■■■■■■■■■■■■-]
UF: SP
CNAE: Transporte rodoviário de carga, exceto produtos perigosos e mudanças, intermunicipal, interestadual e internacional

[illegible][illegible]

#4 RODONAVES TRANSPORTES E ENCOMENDAS LTDA
Score: 0.9947 [■■■■■■■■■■■■■■■■■■■■-]
UF: SP
CNAE: Transporte rodoviário de carga, exceto produtos perigosos e mudanças, intermunicipal, interestadual e internacional

#5 RIUMA COMERCIO E PARTICIPACOES LTDA
Score: 0.9943 [■■■■■■■■■■■■■■■■■■■■■-]
UF: SP
CNAE: Transporte rodoviário de carga, exceto produtos perigosos e mudanças, intermunicipal, interestadual e internacional

#6 AMERICANAS S.A - EM RECUPERAÇÃO JUDICIAL
Score: 0.9940 [■■■■■■■■■■■■■■■-]
UF: SP
CNAE: Transporte rodoviário de carga, exceto produtos perigosos e mudanças, intermunicipal, interestadual e internacional

#7 J&T EXPRESS BRAZIL LTDA.
Score: 0.9936 [██████████████████████]
IIF: RS

47

Novamente somente as locadoras relevantes e de mesmo porte foram trazidas pelo algoritmo.

A viabilidade de implantação do sistema é sustentada pela baixa latência observada nos testes experimentais. A arquitetura baseada em Spark permite o processamento distribuído da carga total da Receita Federal, enquanto o monitoramento contínuo fundamenta-se na análise da evolução temporal da base cadastral brasileira.

Assim, a solução proposta não apenas soluciona o problema de similaridade, mas o faz de forma escalável e resiliente a novas atualizações de dados."

7. CONCLUSÃO

A presente pesquisa demonstrou a viabilidade e a eficácia da utilização de técnicas de Ciência de Dados e Aprendizado de Máquina para a otimização de processos de prospecção B2B no cenário brasileiro. Através do processamento da base de dados pública de CNPJs do Ministério da Fazenda, foi possível desenvolver um motor de recomendação híbrido que supera as limitações das buscas manuais e de filtros estáticos de mercado.

8.1. Resumo dos Principais Resultados

Os experimentos realizados validaram que a combinação do algoritmo *K-Nearest Neighbors* (KNN) para variáveis estruturais (como capital social e porte) com a Similaridade de Cosseno aplicada a vetores TF-IDF (para descrição de atividades econômicas) oferece um ranqueamento de alta precisão. O sistema demonstrou uma latência de resposta inferior a 0,1 segundos por consulta, comprovando a eficiência computacional necessária para aplicações em larga escala que envolvem milhões de registros. A assertividade média observada nos testes de similaridade setorial confirmou que o modelo é capaz de identificar concorrentes diretos e empresas com perfis operacionais análogos com alta relevância.

8.2. Contribuições do Projeto

Este trabalho contribui para a área de análise de dados ao apresentar uma arquitetura capaz de lidar com a esparsidade e o volume massivo de dados governamentais (*Big Data*). Do ponto de vista prático, a solução proposta democratiza o acesso a ferramentas de inteligência de vendas, permitindo que empresas de tecnologia, especialmente no nicho de IoT, identifiquem potenciais clientes (*leads*) com maior aderência ao seu *Ideal Customer Profile* (ICP), reduzindo o Custo de Aquisição de Clientes (CAC) e aumentando a eficiência das equipes comerciais.

8.3. Limitações Identificadas


Apesar do desempenho satisfatório, o projeto encontrou limitações relacionadas à qualidade dos dados originais, como a desatualização de alguns campos cadastrais na base da Receita Federal e a ausência de informações sobre o faturamento real das empresas, o que obrigou o uso do Capital Social como *proxy* de porte. Adicionalmente, o processamento de toda a base nacional em ambientes de nuvem limitados apresentou desafios de memória, exigindo otimizações locais e uso de bibliotecas de processamento distribuído como o PySpark.

8.4. Impacto Prático e Trabalhos Futuros

O impacto imediato deste sistema é a transformação da prospecção reativa em uma estratégia *data-driven* proativa. Como desdobramentos futuros para este trabalho, sugerem-se:

- **Melhorias Técnicas:** Implementação de Redes Neurais de Grafos (*Graph Neural Networks*) para mapear o ecossistema de sócios e participações societárias, permitindo identificar grupos econômicos.
- **Aprimoramento da Diversidade:** Desenvolvimento de técnicas de *re-ranking* para mitigar o viés de concentração geográfica (evitando que empresas de grandes centros como São Paulo dominem as recomendações).

- **Integração de Novas Fontes:** Cruzamento dos dados de CNPJ com sinais externos, como o *tech stack* identificado em sites institucionais ou dados de comércio exterior, para refinar ainda mais o score de propensão tecnológica.
- **Escalabilidade:** Migração da infraestrutura para um ambiente de microsserviços em nuvem com escalonamento automático para suportar múltiplos usuários simultâneos.



REFERÊNCIAS

AMARASINGHE, Sean. **Cosine Similarity vs Euclidean Distance:** The One Explanation Every Data Scientist Needs. Medium, 29 dez. 2025. Disponível em: <https://medium.com/@szaranger/cosine-similarity-vs-euclidean-distance-the-one-explanation-every-data-scientist-needs-2acf3337d49e>

Acesso em: 28 mar. 2026.

BRASIL. Ministério da Gestão e da Inovação em Serviços Públicos. **Portal de Dados Abertos**. Disponível em: <https://dados.gov.br/>. Acesso em: 18 ago. 2025, 05 set. 2025 e 03 mar. 2026.

BRASIL. Receita Federal. **Dados Públicos de CNPJ**. Disponível em: <https://www.gov.br/pt-br/dados-do-governo-federal>. Acesso em: 18 ago. 2025, 05 set. 2025 e 03 mar. 2026.

UNIVERSIDADE PRESBITERIANA MACKENZIE. **Guia Mackenzie de trabalhos acadêmicos**. 2. ed. São Paulo: Editora Mackenzie, 2021. *E-book*.

GLOSSÁRIO

5G, 4G, 3G e 2G	São gerações de tecnologia de rede móvel celular que representam avanços sucessivos na velocidade, capacidade e qualidade de comunicação sem fio.
edge-to-cloud	Edge-to-cloud é um paradigma tecnológico que conecta dispositivos e sistemas na borda da rede (edge) com serviços de nuvem, permitindo a coleta, processamento e análise de dados próximos à origem, com posterior transmissão e armazenamento na nuvem para maior capacidade computacional e análises avançadas.
eSIM / iSIM	eSIM (SIM embutido) e iSIM (SIM integrado) são tecnologias de SIM digital que permitem a ativação remota de serviços de telefonia móvel sem a necessidade de um cartão SIM físico, sendo o eSIM embutido no dispositivo e o iSIM integrado diretamente ao chip do processador.
Gateways	São dispositivos que atuam como intermediários na rede, conectando e facilitando a comunicação entre diferentes redes e protocolos, permitindo a transferência de dados entre sistemas distintos.
GNSS	Sistema Global de Navegação por Satélite, refere-se a sistemas de satélite, como GPS, que fornecem informações de localização e navegação a receptores em todo o mundo.
Indústria 4.0	Indústria 4.0 é a integração de tecnologias avançadas, como IoT, inteligência artificial e automação, nos processos de fabricação para criar fábricas inteligentes e eficientes.
IoT	A Internet das Coisas (IoT) é a conexão de dispositivos físicos, como eletrodomésticos, veículos e sensores, à internet, permitindo que eles coletem e troquem dados, automatizem processos e sejam controlados remotamente para melhorar a eficiência e a conveniência.
LPWA	LPWA (Low-Power Wide-Area) é uma categoria de redes de comunicação sem fio projetada para fornecer conectividade de longo alcance com baixo consumo de energia, ideal para dispositivos IoT.
LTE, LTE-M, NB-IoT	LTE é uma tecnologia de rede móvel de alta velocidade; LTE-M é uma versão otimizada do LTE para dispositivos IoT com menor consumo de energia; NB-IoT é uma tecnologia de rede que proporciona conectividade eficiente para dispositivos IoT com baixa largura de banda e longo alcance.
Milestone	Milestone é um marco significativo no progresso de um projeto ou processo, representando a conclusão de uma etapa importante.
Módulos celulares	Módulos celulares são componentes que permitem dispositivos se conectarem a redes móveis para transmitir e receber dados sem fio.
ODM	ODM (Original Design Manufacturer) é uma empresa que projeta e fabrica produtos que são vendidos e comercializados sob a marca de outra empresa.
Redes Privadas	Redes privadas são redes de comunicação utilizadas exclusivamente por uma organização ou grupo, oferecendo maior segurança e controle em comparação às redes públicas.
Repositório	Um repositório é um local central onde dados, arquivos ou recursos são armazenados e organizados para fácil acesso e gerenciamento.
SIMCARD/Cartão de dados	SIMCARD, ou Cartão de Dados, é um chip que armazena informações de identificação do assinante e permite a conexão e a comunicação em redes móveis.
Smart grids	Smart grids são redes elétricas inteligentes que utilizam tecnologia digital para monitorar, gerenciar e otimizar a geração, distribuição e consumo de energia, melhorando a eficiência e a confiabilidade do sistema elétrico.
Utilities	Utilities são serviços essenciais, como fornecimento de água, eletricidade, gás e

	saneamento, que atendem às necessidades básicas de uma comunidade.
Wi-Fi, Bluetooth, Zigbee, LoRA, WiSun	Tecnologias de comunicação não celular são métodos de transmissão de dados que não dependem de redes móveis, como Wi-Fi, Bluetooth, Zigbee e LoRa, usadas para conectar dispositivos dentro de uma rede local ou em distâncias mais curtas.
Smart Cities	Smart Cities são cidades que utilizam tecnologias digitais e de comunicação para melhorar a eficiência dos serviços urbanos, como transporte, energia e gestão de resíduos, visando criar um ambiente mais sustentável e conectado para seus habitantes.
B2B	O termo B2B (Business to Bussines) refere-se a transações comerciais realizadas entre duas empresas. É o foco do seu trabalho com a base de dados do CNPJ.
B2C	O termo B2C (Business to Customer) refere-se a empresas que vendem diretamente para o consumidor final (pessoa física). É o modelo clássico de plataformas como Netflix, Amazon ou Spotify

Tabela 2 – Glossário.

APÊNDICE A – LINK DO VIDEO NO YOUTUBE

<https://youtu.be/U5QHtly2-5Y>

APÊNDICE B – LINK PARA GITHUB

LOCAL

Git Hub: https://github.com/engricardofranco/mack_ds_projeto_aplicado_iii.git

Obs: Por razões relacionadas a limitações técnicas referentes à possibilidade de armazenamento e processamento dos dados e, também, visando facilitar o desenvolvimento do trabalho em equipe, optamos por criar a estrutura do Data Lake no Drive, em vez de utilizar o GitHub, como havia sido planejado inicialmente.

APÊNDICE C – LINK PARA DATASET

LOCAL

Google Drive:

https://drive.google.com/drive/folders/1GTqt0pCETLFsmy2CKfXlzdjR38SY3Lrf?usp=drive_link

Obs: Por razões relacionadas a limitações técnicas referentes à possibilidade de armazenamento e processamento dos dados e, também, visando facilitar o desenvolvimento do trabalho em equipe, optamos por criar a estrutura do Data Lake no Drive, em vez de utilizar o GitHub, como havia sido planejado inicialmente.

ANEXO A – LAYOUT DAS TABELAS PARA DADOS ABERTOS DO CNPJ

Novo Layout para os DADOS ABERTOS do CNPJ:

EMPRESAS	
Campo	Descrição
CNPJ BÁSICO	NÚMERO BASE DE INSCRIÇÃO NO CNPJ (OITO PRIMEIROS DÍGITOS DO CNPJ).
RAZÃO SOCIAL / NOME EMPRESARIAL	NOME EMPRESARIAL DA PESSOA JURÍDICA
NATUREZA JURÍDICA	CÓDIGO DA NATUREZA JURÍDICA
QUALIFICAÇÃO DO RESPONSÁVEL	QUALIFICAÇÃO DA PESSOA FÍSICA RESPONSÁVEL PELA EMPRESA
CAPITAL SOCIAL DA EMPRESA	CAPITAL SOCIAL DA EMPRESA
PORTE DA EMPRESA	CÓDIGO DO PORTE DA EMPRESA: 00 - NÃO INFORMADO 01 - MICRO EMPRESA 03 - EMPRESA DE PEQUENO PORTE 05 - DEMAIS
ENTE FEDERATIVO RESPONSÁVEL	O ENTE FEDERATIVO RESPONSÁVEL É PREENCHIDO PARA OS CASOS DE ÓRGÃOS E ENTIDADES DO GRUPO DE NATUREZA JURÍDICA 1XXX. PARA AS DEMAIS NATUREZAS, ESTE ATRIBUTO FICA EM BRANCO.

ESTABELECIMENTOS	
Campo	Descrição
CNPJ BÁSICO	NÚMERO BASE DE INSCRIÇÃO NO CNPJ (OITO PRIMEIROS DÍGITOS DO CNPJ).
CNPJ ORDEM	NÚMERO DO ESTABELECIMENTO DE INSCRIÇÃO NO CNPJ (DO NONO ATÉ O DÉCIMO SEGUNDO DÍGITO DO CNPJ).
CNPJ DV	DÍGITO VERIFICADOR DO NÚMERO DE INSCRIÇÃO NO CNPJ (DOIS ÚLTIMOS DÍGITOS DO CNPJ).
IDENTIFICADOR MATRIZ/FILIAL	CÓDIGO DO IDENTIFICADOR MATRIZ/FILIAL: 1 - MATRIZ 2 - FILIAL

NOME FANTASIA	CORRESPONDE AO NOME FANTASIA
SITUAÇÃO CADASTRAL	CÓDIGO DA SITUAÇÃO CADASTRAL: 01 - NULA 2 - ATIVA 3 - SUSPENSA 4 - INAPTA 08 - BAIXADA
DATA SITUAÇÃO CADASTRAL	DATA DO EVENTO DA SITUAÇÃO CADASTRAL
MOTIVO SITUAÇÃO CADASTRAL	CÓDIGO DO MOTIVO DA SITUAÇÃO CADASTRAL
NOME DA CIDADE NO EXTERIOR	NOME DA CIDADE NO EXTERIOR
PAIS	CÓDIGO DO PAIS
DATA DE INÍCIO ATIVIDADE	DATA DE INÍCIO DA ATIVIDADE
CNAE FISCAL PRINCIPAL	CÓDIGO DA ATIVIDADE ECONÔMICA PRINCIPAL DO ESTABELECIMENTO
CNAE FISCAL SECUNDÁRIA	CÓDIGO DA(S) ATIVIDADE(S) ECONÔMICA(S) SECUNDÁRIA(S) DO ESTABELECIMENTO
TIPO DE LOGRADOURO	DESCRIÇÃO DO TIPO DE LOGRADOURO
LOGRADOURO	NOME DO LOGRADOURO ONDE SE LOCALIZA O ESTABELECIMENTO.
NÚMERO	NÚMERO ONDE SE LOCALIZA O ESTABELECIMENTO. QUANDO NÃO HOUVER PREENCHIMENTO DO NÚMERO HAVERÁ 'S/N'.
COMPLEMENTO	COMPLEMENTO PARA O ENDEREÇO DE LOCALIZAÇÃO DO ESTABELECIMENTO
BAIRRO	BAIRRO ONDE SE LOCALIZA O ESTABELECIMENTO.
CEP	CÓDIGO DE ENDEREÇAMENTO POSTAL REFERENTE AO LOGRADOURO NO QUAL O ESTABELECIMENTO ESTA LOCALIZADO
UF	SIGLA DA UNIDADE DA FEDERAÇÃO EM QUE SE ENCONTRA O ESTABELECIMENTO
MUNICÍPIO	CÓDIGO DO MUNICÍPIO DE JURISDIÇÃO ONDE SE ENCONTRA O ESTABELECIMENTO

DDD 1	CONTÉM O DDD 1
TELEFONE 1	CONTÉM O NÚMERO DO TELEFONE 1
DDD 2	CONTÉM O DDD 2
TELEFONE 2	CONTÉM O NÚMERO DO TELEFONE 2
DDD DO FAX	CONTÉM O DDD DO FAX
FAX	CONTÉM O NÚMERO DO FAX
CORREIO ELETRÔNICO	CONTÉM O E-MAIL DO CONTRIBUINTE
SITUAÇÃO ESPECIAL	SITUAÇÃO ESPECIAL DA EMPRESA
DATA DA SITUAÇÃO ESPECIAL	DATA EM QUE A EMPRESA ENTROU EM SITUAÇÃO ESPECIAL

DADOS DO SIMPLES	
Campo	Descrição
CNPJ BÁSICO	NÚMERO BASE DE INSCRIÇÃO NO CNPJ (OITO PRIMEIROS DÍGITOS DO CNPJ).
OPÇÃO PELO SIMPLES	INDICADOR DA EXISTÊNCIA DA OPÇÃO PELO SIMPLES. S - SIM N - NÃO EM BRANCO - OUTROS
DATA DE OPÇÃO PELO SIMPLES	DATA DE OPÇÃO PELO SIMPLES
DATA DE EXCLUSÃO DO SIMPLES	DATA DE EXCLUSÃO DO SIMPLES
OPÇÃO PELO MEI	INDICADOR DA EXISTÊNCIA DA OPÇÃO PELO MEI S - SIM N - NÃO EM BRANCO - OUTROS
DATA DE OPÇÃO PELO MEI	DATA DE OPÇÃO PELO MEI
DATA DE EXCLUSÃO DO MEI	DATA DE EXCLUSÃO DO MEI

SÓCIOS	
Campo	Descrição
CNPJ BÁSICO	NÚMERO BASE DE INSCRIÇÃO NO CNPJ (CADASTRO NACIONAL DA PESSOA JURÍDICA).
IDENTIFICADOR DE SÓCIO	CÓDIGO DO IDENTIFICADOR DE SÓCIO 1 - PESSOA JURÍDICA 2 - PESSOA FÍSICA 3 - ESTRANGEIRO
NOME DO SÓCIO (NO CASO PF) OU RAZÃO SOCIAL (NO CASO PJ)	NOME DO SÓCIO PESSOA FÍSICA OU A RAZÃO SOCIAL E/OU NOME EMPRESARIAL DA PESSOA JURÍDICA E/OU NOME DO SÓCIO/RAZÃO SOCIAL DO SÓCIO ESTRANGEIRO
CNPJ/CPF DO SÓCIO	CPF OU CNPJ DO SÓCIO (SÓCIO ESTRANGEIRO NÃO TEM ESTA INFORMAÇÃO).
QUALIFICAÇÃO DO SÓCIO	CÓDIGO DA QUALIFICAÇÃO DO SÓCIO
DATA DE ENTRADA SOCIEDADE	DATA DE ENTRADA NA SOCIEDADE
PAÍS	CÓDIGO PAÍS DO SÓCIO ESTRANGEIRO
REPRESENTANTE LEGAL	NÚMERO DO CPF DO REPRESENTANTE LEGAL
NOME DO REPRESENTANTE	NOME DO REPRESENTANTE LEGAL
QUALIFICAÇÃO DO REPRESENTANTE LEGAL	CÓDIGO DA QUALIFICAÇÃO DO REPRESENTANTE LEGAL
FAIXA ETÁRIA	CÓDIGO CORRESPONDENTE À FAIXA ETÁRIA DO SÓCIO

Será gerado um arquivo para cada tabela de domínio listado abaixo:

PAÍSES	
Campo	Descrição
CÓDIGO	CÓDIGO DO PAÍS
DESCRIÇÃO	NOME DO PAÍS

MUNICÍPIOS	
-------------------	--

Campo	Descrição
CÓDIGO	CÓDIGO DO MUNICÍPIO
DESCRIÇÃO	NOME DO MUNICÍPIO

QUALIFICAÇÕES DE SÓCIOS	
Campo	Descrição
CÓDIGO	CÓDIGO DA QUALIFICAÇÃO DO SÓCIO
DESCRIÇÃO	NOME DA QUALIFICAÇÃO DO SÓCIO

NATUREZAS JURÍDICAS	
Campo	Descrição
CÓDIGO	CÓDIGO DA NATUREZA JURÍDICA
DESCRIÇÃO	NOME DA NATUREZA JURÍDICA

CNAEs	
Campo	Descrição
CÓDIGO	CÓDIGO DA ATIVIDADE ECONÔMICA
DESCRIÇÃO	NOME DA ATIVIDADE ECONÔMICA

1. Formato do arquivo

O formato do arquivo deve ter o padrão de carga automática em Bancos de Dados Relacionais (RDBMS – Relational Database Management Systems); usar ponto e vírgula (;) como separador de atributos;

2. O campo 169 (CNPJ/CPF DO SÓCIO) e 271 (CNPJ/CPF DO REPRESENTANTE) do layout de sócios devem ser descaracterizados conforme a regra abaixo:

Ocultação de informações pessoais sigilosas como no caso do CPF, o qual deve ser descaracterizado por meio da ocultação dos três primeiros dígitos e dos dois dígitos verificadores, conforme orientação disposta no art. 129 § 2o da Lei no 13.473/2017 (LDO 2018).

3. Campo Ente Federativo Responsável – EFR, no Layout Principal (Dados Cadastrais):

Deve ser preenchido para os casos de Órgãos e Entidades do grupo de Natureza Jurídica 1XX. Para as demais naturezas, esse atributo fica em branco.

Exemplos de texto que deverão aparecer no arquivo final: UNIÃO; DISTRITO FEDERAL; BAHIA; para municípios, exibir também a sigla da UF: SÃO PAULO – SP; BELO HORIZONTE – MG;

4. Campo Faixa Etária, no Layout Sócios:

Baseada na data de nascimento do CPF de cada sócio, deverá ser criado o valor para o campo "Faixa Etária" conforme a regra abaixo:

- 1 para os intervalos entre 0 a 12 anos;
- 2 para os intervalos entre 13 a 20 anos;
- 3 para os intervalos entre 21 a 30 anos;
- 4 para os intervalos entre 31 a 40 anos;
- 5 para os intervalos entre 41 a 50 anos;
- 6 para os intervalos entre 51 a 60 anos;
- 7 para os intervalos entre 61 a 70 anos;
- 8 para os intervalos entre 71 a 80 anos; - 9 para maiores de 80 anos.
- 0 para não se aplica.

5. O Campo CNAE FISCAL SECUNDÁRIA no Layout Estabelecimentos:

Deve ser preenchido com cada ocorrência sendo separada por vírgula, para os casos de várias ocorrências.